


MSc Wirtschaftsinformatik
Digital Finance - Anwendung und Technologien

Pattern Recognition für Kursprognosen mit (Derivative) Dynamic Time Warping



Eingereicht am 31. Dezember 2024 von

Lüthi Yann, Requirements Engineer, Breitfeldstrasse 36, 3014 Bern,
yann.luethi@students.bfh.ch

Knecht Pascal, Expert System Engineer, Roosweg 11, 5423 Freienwil,
pascal.knecht@students.ffhs.ch

Inhaltsverzeichnis

Abstract

1	Einleitung	4
2	Theoretischer Hintergrund	6
2.1	DTW.....	6
2.2	Derivative DTW.....	6
2.3	Subsequence DTW.....	7
2.4	Savitzky-Golay-Algorithmus.....	7
2.5	RW-Funktion.....	7
3	Projektplanung.....	8
4	Datenbeschreibung.....	9
4.1	Auswahl von Assets.....	10
4.2	Technische Anmerkungen	10
5	Reflektion.....	11
5.1	Fazit zum Projekt.....	11
5.2	Mehrwert unserer Arbeit	11
5.3	Herausforderungen und Schwierigkeiten.....	12
5.4	Mögliche zukünftige Erweiterungen.....	13

Anhang

- A Literaturverzeichnis
- B Tabellenverzeichnis

Abstract

In diesem Projekt wurde die Anwendung von Dynamic Time Warping (DTW) zur Mustererkennung in Zeitreihen analysiert und implementiert. Dabei wurden sowohl fundamentale Implementierungen wie die Glättung und Normalisierung von Daten als auch erweiterte Techniken wie die Ableitung und subsequence-basierte Analyse verwendet. Ziel war es, Handelsstrategien auf Basis der Ähnlichkeit von Teilsequenzen historischer Kursverläufe zu entwickeln und zu evaluieren.

Das Projekt umfasste die Erstellung eines Jupyter Notebooks, dass die Funktionalitäten von DTW und derivative DTW (DDTW) integriert. Es wurden Methoden zur Identifikation ähnlicher Sequenzen, zur Generierung von Handelssignalen und zur Prognose zukünftiger Kursentwicklungen entwickelt und getestet. Zusätzlich wurde die Strategie mit etablierten Referenzstrategien verglichen und auf eine Vielzahl von Assets angewendet, um ihre Robustheit und Generalisierbarkeit zu bewerten.

Die Ergebnisse zeigen, dass die entwickelte Subsequence-DDTW-Strategie auf den ausgewählten 15 Assets aus fünf unterschiedlichen «Asset-Klassen» im betrachteten Zeitraum der letzten fünf Jahre sowohl eine solide Rendite als auch eine überdurchschnittliche risikoadjustierte Performance erzielt. Mit einem Sharpe Ratio von 0,54 und einem Calmar Ratio von 0,5 übertrifft sie andere getestete Strategien in mehreren Metriken.

Einschränkungen wurden hingegen bei der Anwendung von DTW für das Clustering von Asset-Typen beobachtet, was möglicherweise auf die Vielschichtigkeit der Einflussfaktoren auf Kursverläufe zurückzuführen ist.

Das Projekt hebt das Potenzial von DTW in der algorithmischen Finanzanalyse hervor, zeigt jedoch auch deren Limitationen auf. Die Ergebnisse bieten eine Grundlage für weiterführende Untersuchungen und Anwendungen, insbesondere im Bereich der Integration von DTW-basierten Signalen in aggregierte Handelsstrategien.

Der Python-Code, sowie die detaillierten Ergebnisse, Analysen und technischen Beschreibungen sind in Form eines Jupyter Notebooks über folgendes GitHub-Repository verfügbar: <https://github.com/yannluethi/DIFA>

1 Einleitung

In der heutigen Finanzwelt spielen Technologien eine immer wichtigere Rolle. Finanzinstitute, Hedgefonds, und private Investoren setzen immer öfter auf maschinelles Lernen und Big Data Analysen, um Entscheidungen zu treffen und Wettbewerbsvorteile zu erlangen. Diese Technologien ermöglichen es, Finanzdaten zu verarbeiten und daraus Erkenntnisse über Trends zu gewinnen (Cohen, 2022). Besonders nützlich ist dabei die algorithmische Mustererkennung, die genutzt wird, um wiederkehrende Muster in Finanzdaten zu identifizieren. Die Erkennung von Mustern kann dazu beitragen, zukünftige Kursbewegungen vorherzusagen und Handelsentscheidungen automatisiert zu treffen (Lin et al., 2021).

Das Modul DIFA (Digital Finance – Anwendungen und Technologien) zielt darauf ab, Studierenden ein Verständnis für neue Technologien und deren Anwendung im Finanzbereich zu vermitteln. In diesem Kontext ist unser Semesterprojekt einzuordnen, bei dem wir uns mit der algorithmischen Mustererkennung befassen. Genauer werden wir uns mit Kapitel 9 «Dynamic Time Warping for Pattern Recognition» des Buches «Technical Analysis for Algorithmic Pattern Recognition» von Tsinaslanidis und Zapranis (Tsinaslanidis & Zapranis, 2016) auseinandersetzen. Das Kapitel beschreibt die Methode des Dynamic Time Warping (DTW), die speziell zur Erkennung von Mustern in Zeitreihen entwickelt wurde und sich für die Analyse von Finanzdaten eignet, da sie zeitliche Unterschiede und Geschwindigkeit von Mustern berücksichtigen kann.

Darüber hinaus beschreiben Tsinaslanidis & Zapranis (2016) ergänzende Verfahren wie Derivative DTW zur Erkennung dynamischer Veränderungen und Subsequence DTW zur Identifizierung spezifischer Referenzmuster in längeren Zeitreihen. Der Savitzky-Golay-Algorithmus wird dabei verwendet, um die Daten zu glätten, während die RW-Funktion zur Identifikation lokaler Minima der DTW-Distanzen und somit zur Erkennung ähnlicher Sequenzen dient. Diese Techniken unterstützen die Entscheidungsfindung im algorithmischen Handel, indem sie Rauschen reduzieren und Trends in den Daten hervorheben.

Für das Projekt haben wir folgende Ziele definiert:

- Anwendung des beschriebenen Verfahrens basierend auf DTW zur Identifikation von Mustern innerhalb von Finanzzeitreihen:
 - Verwendung des Savitzky-Golay-Algorithmus zur Glättung der Daten
 - Einsatz von DDTW zur Analyse der ersten Ableitung von Zeitreihen.
 - Erkennung spezifischer Referenzmuster in langen Zeitreihen mittels Subsequence DDTW in Verbindung mit der RW-Funktion zur Identifikation von lokalen Minima der DTW-Distanzen.
- Erweiterte Analysen zur Prognose von Trends:
 - Prüfung, ob Subsequence DDTW für kurzfristige Trendprognosen innerhalb einer Zeitreihe geeignet ist, sowie deren Ableitung in Handelssignale und -strategien.
- Clustering von Finanzassets:
 - Prüfung, ob DTW zur Identifikation des Assettyps (wie etwa Technologie-, Konsumgüter- oder Industrie-Aktien bzw. Rohstoffe oder Indizes) von noch nicht entsprechend klassifizierten Assets genutzt werden kann.

Für die Analyse verwenden wir historische Finanzzeitreihen, die verschiedene Anlageklassen wie Aktien, Indizes und Rohstoffe abdecken können. Im Fokus steht dabei insbesondere der tägliche Schlusskurs, der entscheidende Einblicke in die Kursentwicklung bietet. Die Auswahl der spezifischen Finanzzeitreihen erfolgt während der Umsetzungsphase, wobei wir die Implementierung generisch halten, um den Austausch der Zeitreihen mit minimalem Aufwand zu ermöglichen.

Als Entwicklungsumgebung setzen wir Visual Studio Code ein, das eine leistungsstarke Plattform für das Schreiben, Debuggen und Testen von Code bietet. Ausserdem nutzen wir ein Jupyter Notebook, um interaktive Analysen durchzuführen, Ergebnisse zu visualisieren und den Workflow zu dokumentieren. Zur Versionskontrolle und kollaborativen Arbeit verwenden wir GitHub. GitHub ermöglicht es uns, den Code zentral zu speichern, Änderungen nachzuverfolgen und effizient im Team zusammenzuarbeiten.

2 Theoretischer Hintergrund

In diesem Kapitel werden die theoretischen Grundlagen für die im Projekt verwendeten Techniken vorgestellt. Im Fokus stehen DTW und seine Varianten Subsequence DTW und Derivative DTW sowie weitere unterstützende Methoden wie der Savitzky-Golay-Algorithmus und die RW-Funktion, die in der algorithmischen Mustererkennung zur Anwendung kommen. Die Umsetzung, Parametrisierung und Verknüpfung dieser Ansätze werden im Jupyter-Notebook aufgezeigt, beschrieben und soweit möglich visualisiert.

2.1 DTW

Dynamic Time Warping ist ein Algorithmus, der dazu dient, die Ähnlichkeit zwischen zwei Zeitreihen zu bestimmen, auch wenn diese unterschiedlich lang sind oder sich in ihrer zeitlichen Abfolge unterscheiden. Ursprünglich wurde DTW in den 1960er-Jahren für die Spracherkennung entwickelt und später auf andere Bereiche, wie zum Beispiel die Finanzanalyse, übertragen. DTW findet die beste Übereinstimmung zwischen zwei Sequenzen, indem es zeitliche Unterschiede ausgleicht. Dazu werden alle möglichen Vergleichspunkte zwischen den Sequenzen analysiert, sodass eine optimale Anpassung erreicht wird und die «Kosten» für diese Anpassung im Sinne eines Distanzmasses berechnet werden können. In der Finanzanalyse ist DTW nützlich, um Muster in Kursverläufen zu erkennen, die sich über unterschiedliche Zeiträume erstrecken (Tsinaslanidis & Zapanis, 2016).

2.2 Derivative DTW

DDTW ist eine Modifikation von DTW, bei der anstelle der Rohdaten die Ableitungen der Zeitreihen verwendet werden. Diese Methode ist besonders nützlich, wenn Preisverläufe stark variieren oder verrauscht sind, da sie empfindlicher auf Änderungen in der Steigung reagiert. Durch die Analyse der ersten Ableitungen werden nicht nur Sequenzen verglichen, sondern auch dynamische Veränderungen in den Kursverläufen identifiziert. Um störende Einflüsse zu reduzieren, wird vor der Anwendung von DDTW oft eine Glättung der Daten, beispielsweise mittels Savitzky-Golay-Algorithmus, vorgenommen (Tsinaslanidis & Zapanis, 2016).

2.3 Subsequence DTW

Subsequence DTW ist eine Erweiterung von DTW, bei der Muster innerhalb längerer Zeitreihen ermittelt werden. Diese Methode sucht nach Untersequenzen, die einer kürzeren Referenzsequenz ähneln, und kann so wiederkehrende Muster identifizieren. In der Praxis wird hierfür die DTW-Distanz verwendet, um die Ähnlichkeit zwischen der Referenz und den Untersequenzen zu quantifizieren und nur Muster zu berücksichtigen, die unter einem definierten Schwellenwert liegen. Diese Technik ist besonders hilfreich, wenn spezifische Muster über längere Zeiträume hinweg verfolgt werden sollen, wie z.B. bestimmte saisonale Trends in Finanzmärkten. Ein Vorteil von Subsequence (D)DTW ist, dass es Muster unabhängig von ihrer Zeitlänge oder Preisniveau erkennt, was in der Finanzanalyse von besonderem Interesse ist (Tsinaslanidis & Zapranis, 2016)

2.4 Savitzky-Golay-Algorithmus

Der Savitzky-Golay-Algorithmus ist eine Methode zur Glättung von Zeitreihen, die zur Rauschunterdrückung dient, ohne wichtige Signalmerkmale zu verlieren. Die Methode passt über ein gleitendes Fenster eine Polynomgleichung der kleinsten Quadrate an die Daten an, wodurch Schwankungen geglättet und gleichzeitig signifikante Strukturmerkmale beibehalten werden. In der Finanzanalyse wird der Savitzky-Golay-Algorithmus verwendet, um extreme Schwankungen abzumildern und eine präzisere Erkennung von Wendepunkten oder anderen signifikanten Veränderungen in den Daten zu ermöglichen, was für die Entscheidungsfindung im algorithmischen Handel mittels DDTW nützlich ist (Tsinaslanidis & Zapranis, 2016).

2.5 RW-Funktion

Die RW-Funktion («Rolling Window») wird verwendet, um lokale Maxima und Minima in Zeitreihen zu bestimmen. Sie nutzt ein gleitendes Fenster, das sich iterativ über die Zeitreihe bewegt. Ein Punkt wird als lokales Maximum identifiziert, wenn er grösser ist als alle anderen Werte im Fenster. Analog wird ein lokales Minimum identifiziert, wenn der Punkt kleiner ist als alle anderen Werte im Fenster. Diese Erkennung von Extrempunkten (im vorliegenden Beispiel konkret den Minima der DTW-Distanzen) ist besonders in der Finanzanalyse nützlich, um Wendepunkte in Zeitreihen zu identifizieren (Tsinaslanidis & Zapranis, 2016).

3 Projektplanung

Das Kapitel Projektplanung dient dazu, die zeitliche Struktur und die Aufgabenverteilung im Rahmen unseres Semesterprojekts festzulegen. Es dient als Leitfaden, um die einzelnen Schritte von der Themenwahl bis zur finalen Abgabe systematisch und effizient umzusetzen.

Tätigkeit	Aufteilung	Kalenderwoche																			
		36	37	38	39	40	41	42	43	44	45	46	47	48	49	50	51	52	1	2	
Wahl des Themas	Pascal & Yann																				
Einarbeitung ins Thema	Pascal & Yann																				
Entwicklung des Prototyps	Pascal																				
Vorbereitung der Projektpräsentation	Pascal & Yann																				
Projekt Präsentation	Pascal & Yann																				
Entwickeln und Dokumentieren der Anwendung in Notebook	Pascal																				
Schreiben der Dokumentation	Yann																				
Review der Dokumentation	Pascal																				
Review des Jupyter Notebooks	Yann																				
Abgabetermin	Pascal & Yann																				

Tabelle 1: Projektplanung

4 Datenbeschreibung

Im Rahmen unseres Projekts werden historische Finanzzeitreihen analysiert, die aus verschiedenen Anlageklassen wie Aktien, Indizes und Rohstoffen stammen. Der Fokus liegt dabei auf dem täglichen Schlusskurs ("Close"), da dieser als repräsentativer Wert für die Kursentwicklung gilt. Für die Analysen werden Zeitreihen mit einer Historie von 15 Jahren herangezogen, um eine ausreichend grosse Datenbasis für die Mustererkennung zu gewährleisten. Während die Clusteranalyse das gesamte Datenmaterial berücksichtigt, zeigte sich bei der Kursanalyse und Prognose, dass die Betrachtung der letzten fünf Jahre zu präziseren Ergebnissen führt. Dies möglicherweise aufgrund der Fokussierung auf jüngere Marktbewegungen, die für Prognosen oft relevanter sind. Besonderheiten wie Dividendenzahlungen oder Aktiensplits wurden nicht berücksichtigt, da sie die Zeitreihen in ihrer Struktur verändern könnten. Um Zeitreihen auch unabhängig vom Handelsplatz sowie mit festen, einheitlichen Zeiträumen (z. B. 30 Tage) vergleichbar zu machen, werden Lücken, etwa durch Nicht-Börsentage oder fehlende Datensätze, gezielt mittels "Forward-Fill" geschlossen.

Die Daten stammen von Yahoo Finance, das qualitativ hochwertige historische Finanzdaten bereitstellt. Neben dem Schlusskurs können bei Bedarf zusätzliche Merkmale wie "High", "Low", "Volume" oder "Dividends" abgefragt werden. Die Abfrage der Daten erfolgt über das `yfinance`-Python-Modul, welches eine einfache und effiziente Schnittstelle zur Datenextraktion bietet. Diese Wahl ermöglicht eine flexible Implementierung, bei der die Finanzzeitreihen mit minimalem Aufwand ausgetauscht werden können, um unterschiedliche Analyseziele zu adressieren.

4.1 Auswahl von Assets

Die Anwendung der Dynamic Time Warping (DTW)-Methoden wurde auf unterschiedliche Assetklassen untersucht, um deren Einsatzmöglichkeiten zu evaluieren. Dabei wurde auch geprüft, ob DTW genutzt werden kann, um Assets anhand ihres Kursverlaufs zu clustern und Rückschlüsse auf deren Typ zu ziehen. Folgende fünf Assettypen mit jeweils drei dazugehörigen Assets wurden gewählt:

- **Technologieaktien:** Apple (AAPL), Microsoft (MSFT), Alphabet (GOOGL)
- **Konsumgüteraktien:** Nestlé (NESN), Procter & Gamble (PG), Unilever (UL)
- **Industrieaktien:** ABB (ABBN), Siemens (SIEGY), General Electric (GE)
- **Rohstoffe:** Gold (GC), Silber (SI), Platin (PL)
- **Indizes:** Swiss Market Index (SSMI), DAX (GDAXI), S&P 500 (GSPC)

Die Daten für die insgesamt 15 Assets stammen aus der Yahoo Finance-Datenbank und decken einen Zeitraum von fünfzehn Jahren ab. Weitere Details und Analysen, einschliesslich der vollständigen grafischen Auswertungen und Berechnungen, sind im begleitenden Jupyter Notebook zu finden.

4.2 Technische Anmerkungen

Die Implementation ist generisch gestaltet, sodass sich alternative Zeitreihen leicht einfügen lassen. Dies gewährleistet die Wiederverwendbarkeit des Codes und ermöglicht die Anwendung auf unterschiedliche Anlageklassen und Analyseziele.

5 Reflektion

In diesem abschliessenden Kapitel ziehen wir ein Fazit zu unserem Projekt. Wir fassen die wichtigsten Erkenntnisse zusammen, bewerten den praktischen Nutzen der implementierten Methoden und reflektieren die Relevanz unserer Ergebnisse für weiterführende Anwendungen und Analysen. Die detaillierte und kommentierte Umsetzung mit ausführlicher Besprechung des Vorgehens und der Resultate ist dem Notebook zu entnehmen.

5.1 Fazit zum Projekt

Das Projekt hat gezeigt, dass DTW und seine Varianten leistungsstarke Werkzeuge zur Mustererkennung in Finanzzeitreihen sind. Besonders hervorzuheben ist die Fähigkeit, Muster unabhängig von ihrer zeitlichen Länge und Verschiebung zu identifizieren. Dies eröffnet neue Perspektiven für die Analyse von Kursverläufen und die Entwicklung algorithmischer Handelsstrategien. Die dabei entstandenen visuellen Darstellungen – wie jene der verzerrten Zeitreihen, die Darstellung der Kosten entlang des Warping-Pfads, sowie die Übersichtsgrafik über die Schritte zur Ermittlung ähnlicher Subsequenzen – veranschaulichen die komplexen Berechnungen und Prozesse und bieten einen direkten Mehrwert für Anwender, die diese Methoden verstehen und anwenden möchten.

5.2 Mehrwert unserer Arbeit

Unser Projekt erweitert die theoretischen Ansätze aus Kapitel 9 des Buches von Tsinaslanidis und Zapranis durch eine praxisorientierte Implementierung. Während das Buch die Grundlagen der Mustererkennung mit Dynamic Time Warping (DTW) detailliert, ermöglicht unser entwickelter Code die direkte Anwendung dieser Methodik auf Finanzzeitreihen. Die im Notebook erstellten Beschreibungen und Visualisierungen fördern ein besseres Verständnis des Vorgehens sowie der Ergebnisse und erleichtern die Interpretation der Daten.

Im Rahmen der Arbeit konnte gezeigt werden, dass eine Handelsstrategie, die ausschliesslich auf DTW basiert, in der Lage ist, mit anderen verbreiteten Referenzstrategien zu konkurrieren und diese teilweise sogar zu übertreffen. Dies unterstreicht die Leistungsfähigkeit der Methode. Um die Aussagekraft dieser Feststellungen zu untermauern, wurden die entsprechenden

Handelssimulationen anhand von 15 verschiedenen Assets aus 5 Assetklassen über einen Zeitraum von 5 Jahren durchgeführt. Gleichzeitig wurde festgestellt, dass DTW zwar grundsätzlich für die Kursvorhersage geeignet ist, sich jedoch nicht eignet, um (unklassifizierte) Assets automatisiert Assetklassen (wie Technologie-Aktien, Konsumgüter-Aktien oder Metalle) zuzuordnen.

Ein zentraler Mehrwert unseres Projekts liegt zudem in der Modularität des Codes: Dies erlaubt nicht nur eine Reproduzierbarkeit der Ergebnisse, sondern auch eine einfache Anpassung der Parametrisierung und Erweiterung um zusätzliche Analysewerkzeuge wie Clustering oder Prognosemodelle. Damit stellt unser Projekt eine praktische Ergänzung zur theoretischen Basis des Buches dar und macht die dort beschriebenen Methoden für konkrete Anwendungsfälle greifbar.

5.3 Herausforderungen und Schwierigkeiten

Während der Umsetzung traten unterschiedliche Herausforderungen auf. So erforderte die Komplexität von DTW und seinen Varianten, sowie die ergänzend benötigten Funktionen eine tiefgehende Auseinandersetzung mit der Mathematik hinter den Algorithmen. Durch ein schrittweises Vorgehen, das sich auch im modularen Aufbau des Codes widerspiegelt, konnte diese Komplexität in überschaubare und verständliche Teile zerlegt werden.

Ebenfalls stellte die effiziente Verarbeitung grosser Finanzdatensätze eine technische Hürde dar, die durch Optimierungen der Implementierung, den Einsatz leistungsstarker Bibliotheken wie NumPy, Pandas, SciPy und Backtrader sowie teilweise durch die Reduktion der Datenmenge erfolgreich überwunden wurde.

Schliesslich zeigte sich, dass das implementierte Subsequence-DDTW-Verfahren zahlreiche Parameter umfasst, die optimiert werden können, um im Hinblick auf die Handelsstrategie bestmögliche Ergebnisse zu erzielen. Diese Parameter wurden explorativ und schrittweise optimiert, um eine geeignete und angemessene Parametrisierung zu finden. Das gewählte «Greedy»-Vorgehen ermöglicht die Auswahl lokal guter Parameter, birgt jedoch die Gefahr, global bessere Lösungen zu übersehen. Da das explorative Vorgehen für die Zielsetzung dieser Arbeit ausreichend ist und die Simulation pro Parametrisierungskombination mit hohem Rechenaufwand verbunden ist, wurde auf ein systematisches Durchtesten aller Varianten verzichtet. Die verwendete Parametrisierung ist somit zwar geeignet, erhebt daher keinen Anspruch darauf, die optimale Lösung zu sein.

5.4 Mögliche zukünftige Erweiterungen

Für zukünftige Projekte bietet sich eine Reihe von Erweiterungsmöglichkeiten an:

1. **Integration maschinellen Lernens:** Die Kombination von DTW mit Algorithmen des maschinellen Lernens, wie neuronalen Netzen oder Random Forests, könnte die Prognosegenauigkeit weiter erhöhen. Dabei könnten maschinelle Lernverfahren die Mustererkennung von DTW ergänzen und die Robustheit der Ergebnisse verbessern.
2. **DTW für Handelsstrategie auf Portfolios:** Im Projekt wurde DTW einzig als Handelsstrategie auf einzelnen Assets genutzt, um die Komplexität zu reduzieren. Ein möglicher nächster Schritt wäre die Integration von DTW in eine Portfoliohandelsstrategie. Dabei könnten zusätzliche Potenziale wie die Optimierung der Asset-Allokation oder die Berücksichtigung von Korrelationen und Diversifikation genutzt werden.
3. **Kombination von DTW-Mustererkennung mit anderen Handelssignalen:** Durch die Kombination von DTW mit anderen Handelssignalen (z.B. MovingAverageCrossover) und geeigneter Gewichtung könnte eine performantere Handelsstrategie resultieren.
4. **Echtzeit-Analysen:** Eine Erweiterung des Codes zur Verarbeitung von Live-Daten würde eine direkte Anwendung im algorithmischen Handel ermöglichen.
5. **Erweiterte Visualisierungstools:** Die Entwicklung interaktiver Dashboards könnte die Benutzerfreundlichkeit weiter steigern.
6. **Systematische Optimierung der Parametrisierung:** Die Parametrisierung von DTW für die Mustererkennung wurde bisher explorativ ermittelt. Eine systematische Optimierung, beispielsweise durch Grid-Search oder stochastische Ansätze, könnte die Ergebnisse weiter verbessern. Dabei wäre der erhöhte Rechenaufwand bei der Simulation zu berücksichtigen.
7. **Erweiterung der Datenbasis:** Die Analyse zusätzlicher Märkte, Assets, Assetklassen oder geografischer Regionen könnte die Generalisierbarkeit der Ergebnisse erhöhen und neue Erkenntnisse liefern.

Insgesamt war das Projekt eine wertvolle Gelegenheit, die Brücke zwischen Theorie und Praxis zu schlagen. Die Ergebnisse bieten eine solide Grundlage für weiterführende Untersuchungen und Anwendungen im Bereich der algorithmischen Finanzanalyse.

Anhang

A Literaturverzeichnis

Cohen, G. (2022). Algorithmic Trading and Financial Forecasting Using Advanced Artificial Intelligence Methodologies. *Mathematics*, 10(18), 3302. <https://doi.org/10.3390/math10183302>

Lin, Y., Liu, S., Yang, H., Wu, H., & Jiang, B. (2021). Improving stock trading decisions based on pattern recognition using machine learning technology. *PLOS ONE*, 16(8), e0255558. <https://doi.org/10.1371/journal.pone.0255558>

Tsinaslanidis, P. E., & Zapranis, A. D. (2016). *Technical Analysis for Algorithmic Pattern Recognition*. Springer International Publishing. <https://doi.org/10.1007/978-3-319-23636-0>

B Tabellenverzeichnis

Tabelle 1: Projektplanung	8
---------------------------------	---